

Predicción del reingreso hospitalario a 30 días en pacientes diabéticos: evaluación de KNN, DBSCAN y mezclas gaussianas con validación estadística

Proyecto de Machine Learning · Dataset *Diabetes 130-US hospitals* (UCI, 1999–2008)

Resumen. Objetivo: predecir el reingreso hospitalario en menos de 30 días en pacientes diabéticos y evaluar si existen subgrupos naturales de pacientes. **Métodos:** cohorte de 69 987 pacientes (un encuentro por paciente) derivada de 101 766 hospitalizaciones; prevalencia del desenlace 8.98 %. Se entrenó un clasificador KNN con validación cruzada y se evaluó en un conjunto de prueba independiente (20 %) mediante ROC-AUC, average precision, calibración, intervalos de confianza bootstrap y análisis de curva de decisión. Para el análisis no supervisado se usaron DBSCAN, validado con DBCV, estabilidad de Jaccard y una prueba de ruptura de la discretez (jitter), y una mezcla gaussiana (GMM) con selección por ICL y un procedimiento de consenso. **Resultados:** el KNN ($k = 676$) alcanzó un AUC de 0.639 (IC 95 %: 0.624–0.656), sin diferencia significativa con regresión logística ni con gradient boosting entrenado con las mismas variables; gradient boosting con 32 variables lo superó en 0.014. Tras recalibración isotónica, el decil de mayor riesgo predijo 18.5 % frente a 19.1 % observado. DBSCAN no identificó estructura de densidad (DBCV negativo en todas las configuraciones) y los clusters aparentes correspondieron a niveles de variables discretas. La GMM de consenso produjo cuatro perfiles estables (ARI = 0.88) con tasas de reingreso de 7.0 % a 10.9 %, sin superar a una sola variable como predictor. **Conclusión:** el rendimiento es coherente con la literatura que evalúa sin fuga de información; los pacientes forman un continuo más que grupos discretos.

Palabras clave: reingreso hospitalario; diabetes; k vecinos más cercanos; DBSCAN; modelos de mezcla gaussiana; calibración; validación de clustering.

1. Introducción

El reingreso hospitalario temprano es un indicador de calidad asistencial y un componente importante del costo en salud. Los pacientes diabéticos concentran una fracción relevante de estos reingresos, por lo que identificar a los de mayor riesgo al momento del alta permitiría focalizar intervenciones de seguimiento. El dataset *Diabetes 130-US hospitals* [1] es un referente para este problema; sin embargo, parte de la literatura reporta rendimientos muy altos (AUC > 0.9) obtenidos con procedimientos que filtran información entre entrenamiento y prueba. Los trabajos que evalúan sin fuga reportan AUC entre 0.62 y 0.67 [2].

Este trabajo tiene tres objetivos: (i) construir un clasificador KNN para el reingreso en menos de 30 días; (ii) evaluar con DBSCAN y GMM si existen subgrupos naturales de pacientes; y (iii) someter ambos análisis a una validación estadística explícita: intervalos de confianza, calibración, estabilidad y validación externa.

2. Datos

El dataset contiene 101 766 hospitalizaciones de 71 518 pacientes con 50 variables administrativas. Siguiendo a Strack et al. [1], se excluyeron las altas por fallecimiento (1 652) o a hospicio (771) y 3 registros con sexo inválido, y se conservó el primer encuentro de cada paciente, lo que evita que un mismo paciente aparezca en entrenamiento y en prueba. La cohorte final tiene 69 987 pacientes (Strack et al.: 69 984), con 6 285 reingresos en menos de 30 días (8.98 %). Los faltantes codificados como “?” o como códigos NULL se trataron como categorías explícitas; los diagnósticos ICD-9 se agruparon en 9 capítulos; y a las visitas previas (87–93 % de ceros) se les aplicó $\log(1 + x)$. Se usó una partición estratificada 80/20: entrenamiento con 55 989 pacientes (5 028 eventos) y prueba con 13 998 (1 257 eventos).

3. Métodos

3.1 Clasificación con KNN

Se usaron 8 variables numéricas estandarizadas y codificación one-hot del destino al alta (7 grupos) y del diagnóstico principal (9 capítulos), dentro de un Pipeline ajustado solo con entrenamiento. Los hiperparámetros (k , ponderación y métrica) se seleccionaron por validación cruzada estratificada de 5 folds maximizando ROC-AUC; k se refinó luego con el conjunto de entrenamiento completo. No se aplicó remuestreo del desbalance (p. ej. SMOTE): el desbalance moderado (9 %) se abordó con el umbral de decisión, y el remuestreo deteriora la calibración [8]. Los umbrales de decisión se eligieron con predicciones out-of-fold de entrenamiento bajo tres criterios: máximo F1, recall ≥ 0.80 y capacidad (10 % y 30 % de mayor riesgo). Las probabilidades se recalibraron con regresión isotónica ajustada sobre las predicciones out-of-fold [9]. En prueba se reportan ROC-AUC, average precision (AP), Brier y recall por capacidad, con IC 95 % por bootstrap percentil ($B = 1\ 000$; pareado para diferencias de AUC). Como comparadores se usaron una regresión logística y HistGradientBoosting con las mismas variables, y HistGradientBoosting con las 32 variables disponibles. La utilidad clínica se evaluó con el beneficio neto $BN(p) = VP/n - (FP/n) \cdot p/(1 - p)$ [7].

Función de costo supuesta. Para traducir el riesgo en decisiones se supuso que, para un paciente con riesgo calibrado r , una intervención genera un ahorro esperado $r \cdot E \cdot C_R - C_i$, con $C_R = \text{US\$15 000}$, teleconsulta ($C_i = \text{US\$50}$; $E = 5\ %$) y cita presencial ($C_i = \text{US\$250}$; $E = 20\ %$), con efectividad E constante para todos los pacientes, independiente de su riesgo. Estos valores son supuestos ilustrativos y pueden variar; por eso se evaluaron 12 escenarios de efectividad.

3.2 DBSCAN

Sobre una muestra de 20 000 pacientes con variables estandarizadas, se fijó $\text{minPts} = 2 \cdot d$ [6] y se exploró eps con el gráfico de k -distancia y una grilla. Como índice interno se usó DBCV [3], diseñado para clusters por densidad (rango -1 a 1), en lugar de silhouette, que favorece clusters convexos. La implementación se validó en datos sintéticos de dos lunas: 0.53 para la partición correcta, -0.60 para un corte lineal y -0.72 para etiquetas al azar. La estabilidad por cluster se midió con el Jaccard medio en 10 remuestras (puntos únicos de muestras bootstrap, una adaptación de [4]; ≥ 0.75 estable). Para distinguir estructura real de artefactos de discretización, se sumó ruido $U(-0.5, 0.5)$ a cada variable entera (prueba del jitter), lo que no altera ningún valor al redondear. La

validación externa comparó la tasa de reingreso del ruido con reglas simples (IC de Wilson y riesgo relativo). Se evaluaron dos espacios: 10 variables con visitas previas y 7 variables sin ellas.

3.3 Mezcla gaussiana (GMM)

Se modelaron 7 variables de la hospitalización actual, sin visitas previas, cuya masa en cero provoca componentes degeneradas. Se aplicó jitter $U(-0.5, 0.5)$ (decuantización) y estandarización, con covarianza completa y $\text{reg_covar} = 10^{-4}$. $K \in \{2, \dots, 8\}$ se evaluó con el $\text{ICL} = \text{BIC} + 2 \cdot \Sigma$ entropía de las probabilidades posteriores [5] y con la estabilidad (ARI) entre 5 réplicas con distinto jitter. Para eliminar la dependencia del ruido, el modelo final es un consenso de 10 ajustes sobre la cohorte completa: las componentes se alinearon con el algoritmo húngaro y se promediaron las probabilidades posteriores. La estabilidad por componente se midió frente a 10 ajustes independientes del consenso. La validación externa usó tasas de reingreso con IC de Wilson, χ^2 y V de Cramér, comparadas con una línea base de cuartiles de una sola variable.

4. Resultados

4.1 Clasificación

La configuración óptima fue $k = 676$, distancia manhattan y ponderación uniforme (AUC en validación cruzada 0.640 ± 0.004). El rendimiento en prueba fue equivalente, sin evidencia de sobreajuste (Tabla 1). Con las mismas variables, ni la regresión logística ($\Delta\text{AUC} = +0.005$; IC 95 %: -0.002 a 0.013) ni HistGradientBoosting ($\Delta\text{AUC} = +0.005$; IC 95 %: -0.004 a 0.013) difirieron significativamente del KNN; solo HistGradientBoosting con las 32 variables fue superior ($\Delta\text{AUC} = +0.014$; IC 95 %: 0.004 a 0.024). La ventaja proviene de las variables adicionales y no del algoritmo. En un análisis de ablación, el destino al alta aumentó el AUC de 0.606 a 0.633 y el diagnóstico principal hasta 0.640 . En cambio, añadir las variables destacadas por la literatura lo redujo a 0.634 , lo que es coherente con la sensibilidad de las distancias a atributos poco informativos.

Tabla 1. Rendimiento en el conjunto de prueba ($n = 13\,998$; 1 257 eventos). IC 95 % por bootstrap percentil ($B = 1\,000$).

Modelo	ROC-AUC [IC 95 %]	AP	Brier	Recall top 10 %	Recall top 20 %	Recall top 30 %
KNN ($k = 676$)	0.639 [0.624, 0.656]	0.161	0.0800	0.225	0.359	0.484
Regresión logística	0.645 [0.628, 0.660]	0.168	0.0793	0.231	0.371	0.496
HGB (mismas variables)	0.644 [0.626, 0.661]	0.171	0.0792	0.228	0.361	0.484
HGB (32 variables)	0.653 [0.637, 0.670]	0.187	0.0786	0.247	0.387	0.499
Referencia: prevalencia	0.500	0.090	0.0817	0.100	0.200	0.300

HGB: HistGradientBoosting. AP: average precision. El recall por capacidad es la fracción de los reingresos captados al contactar al x % de pacientes con mayor riesgo. La fila de referencia corresponde a un clasificador sin información.

El KNN subestimó el riesgo en el decil superior (14.5 % predicho frente a 19.4 % observado), un efecto esperable del promedio sobre vecindarios grandes. La recalibración isotónica corrigió la desviación (18.5 % frente a 19.1 %; Brier $0.0800 \rightarrow 0.0796$; Figura 1b). La Tabla 2 muestra el efecto del umbral. Con umbral 0.065 (recall 0.791; IC 95 %: 0.767 – 0.813 ; 8.3 falsas alarmas observadas por reingreso detectado), el beneficio neto del modelo superó al de intervenir a todos solo en 3.5 casos por 1 000 pacientes (30.0 frente a 26.5). Con umbral 0.10 la diferencia fue de 14.7 frente a -11.3 . La política de dos niveles concentró la intervención presencial en el decil superior, cuya tasa observada fue de 18.9 % (IC 95 % de Wilson: 17.0 – 21.0); la teleconsulta alcanzó 11.6 % (10.5 – 12.9) y el resto 6.6 % (6.1 – 7.1), con una cobertura del 49 % de los eventos (47–52). Bajo los supuestos de costo, esta política obtuvo un ahorro neto de US\$41 700 por 1 000 pacientes (IC 95 % bootstrap: $35\,000$ – $48\,500$), frente a US\$19 400 de la mejor política sin modelo, y fue rentable en 11 de los 12 escenarios de sensibilidad.

Tabla 2. Criterios de decisión evaluados en prueba. Los umbrales se eligieron con predicciones out-of-fold de entrenamiento.

Criterio	Umbral	Recall	Precisión	F1	% marcados	Falsos negativos
Umbral por defecto	0.500	0.000	—	0.000	0.0	1 257
Máximo F1	0.098	0.484	0.144	0.222	30.2	649
Recall ≥ 0.80	0.065	0.791	0.107	0.189	66.2	263
Dos niveles (capacidad 10 % + 20 %)	0.124 / 0.096	0.494	0.141	0.220	31.4	636




Figura 1. (a) ROC-AUC en prueba con IC 95 % para el KNN, la regresión logística (mismas variables) y gradient boosting con 32 variables; la banda indica el rango publicado sin fuga de información. (b) Curva de calibración por deciles del KNN antes (Brier 0.0800) y después (Brier 0.0796) de la recalibración isotónica.

4.2 DBSCAN

La configuración inicial (10 variables, $\text{eps} = 1.5$, $\text{minPts} = 20$) produjo 4 clusters y 14.5 % de ruido. Cada cluster coincidió al 100 % con un tipo de visita previa y obtuvo un DBCV de -0.301 , similar al de esa regla trivial (-0.343). Sin las visitas previas, el DBCV fue negativo en toda la grilla (-0.005 a -0.449). La configuración con varios clusters ($\text{eps} = 1.0$, $\text{minPts} = 14$) reprodujo exactamente los niveles 0, 1, 2 y 3 de medicamentos activos, con alta estabilidad (Jaccard 0.85 – 0.94). Con jitter, esos clusters se fundieron en uno solo (Tabla 3). El ruido de la configuración inicial reingresó un 13.0 % (IC 95 %: 11.8 – 14.3 ; $\text{RR} = 1.55$), pero la regla “ ≥ 1 hospitalización previa” fue más discriminante (15.5 %; IC 95 %: 14.1 – 17.0 ; $\text{RR} = 1.89$) y marcó a menos pacientes (11.9 % frente a 14.5 %). El ruido sin visitas previas no se asoció al reingreso ($\text{RR} = 1.02$).

Tabla 3. Diagnóstico de DBSCAN (muestra de 20 000 pacientes; DBCV sobre una submuestra de 4 000; se cuentan los clusters con ≥ 1 % de los pacientes).

Configuración	Clusters	% ruido	DBCV	Jaccard	Interpretación
10 variables, $\text{eps} = 1.5$, $\text{minPts} = 20$	4	14.5	-0.301	0.77–0.99	tipo de visita previa (pureza 100 %)
Regla trivial por tipo de visita	4	—	-0.343	—	referencia
7 variables, $\text{eps} = 1.0$, $\text{minPts} = 14$	4	16.3	-0.449	0.85–0.94	n.º de medicamentos (pureza 100 %)
Ídem, con jitter $U(-0.5, 0.5)$	1	17.7	-0.344	—	los clusters desaparecen

4.3 Mezcla gaussiana

El ICL no identificó un K dominante. Su mínimo promedio se ubicó en $K = 7$ (364 912), pero con alta variabilidad entre réplicas con distinto jitter ($\text{DE} \approx 2\,070$; rango 363 187–367 639), que abarca los valores de $K = 3$ y $K = 4$ (366 007 y 366 100), y con una componente de solo el 5 % de los pacientes. La estabilidad frente al jitter tendió a decrecer con K (ARI de 0.85 con $K = 2$ a 0.49 con $K = 8$; Figura 2a), aunque no de forma monótona: $K = 5$ fue algo más estable que $K = 4$ (0.73 frente a 0.72). Se eligió $K = 4$ por interpretabilidad. Con $K = 4$, los ajustes individuales coincidieron con $\text{ARI} = 0.708$ (mínimo 0.674); el consenso elevó la concordancia entre dos consensos independientes a 0.876 , con Jaccard por componente de 0.81 a 0.85 frente a 10 ajustes independientes. Un 26.4 % de los pacientes mantuvo una probabilidad posterior máxima menor a 0.7. Los cuatro perfiles fueron: estancia corta con procedimiento (21 %), estancia corta sin procedimientos (28 %), muchos diagnósticos (33 %; 98.8 % con exactamente 9 diagnósticos) y estancia larga e intensiva (18 %). Sus tasas de reingreso difirieron significativamente (7.0 % a 10.9 %; χ^2 , $p < 0.001$; Figura 2b), pero con una asociación débil (V de Cramér = 0.053), equivalente a la de los cuartiles de días de hospitalización (0.055) o de número de diagnósticos (0.052).




Figura 2. (a) ARI entre réplicas de la GMM con distinto jitter según K; la línea horizontal indica la concordancia entre dos consensos independientes con K = 4 (cohorte completa; no es directamente comparable con las réplicas individuales, calculadas sobre una muestra de 20 000). (b) Tasa de reingreso en menos de 30 días por perfil del consenso (IC 95 % de Wilson); la línea discontinua indica la prevalencia global.

5. Discusión

El AUC obtenido es coherente con los estudios que evalúan este dataset sin fuga de información (p. ej., XGBoost 0.64 y random forest 0.63 en Liu et al. [2]), y, con las mismas variables, la regresión logística y gradient boosting rindieron igual que el KNN, lo que sugiere que el límite lo impone la información disponible en los registros administrativos más que el algoritmo. El valor óptimo de k, muy grande, convierte al KNN en un estimador suavizado de la tasa local de reingreso, lo que explica tanto la compresión de las probabilidades como la necesidad de recalibrar. La ablación muestra una limitación estructural del KNN con datos mixtos: las variables adicionales, útiles para modelos basados en árboles, diluyen la distancia. La elección del umbral resultó ser un problema de decisión más que estadístico: el análisis de beneficio neto muestra que un umbral orientado a recall alto solo se justifica si el costo de la intervención es muy bajo.

En el análisis no supervisado, la ausencia de estructura de densidad fue consistente entre espacios de variables, parámetros y métricas. La prueba del jitter permitió atribuir los clusters aparentes a la discretización de las variables. Un hallazgo metodológico relevante es que la estabilidad no garantiza validez: los clusters de la configuración sin visitas previas, que desaparecieron con el jitter, tenían Jaccard de 0.85 a 0.94; los de la configuración inicial (hasta 0.99) eran capas reales, pero equivalentes a una regla trivial. En la GMM, el consenso resolvió la variabilidad introducida por la decuantización sin cambiar los perfiles, aunque uno de ellos refleja un artefacto de registro (tope de 9 diagnósticos, más frecuente en los registros recientes).

Limitaciones. Datos administrativos de 1999–2008 de una sola red, sin variables de laboratorio detalladas ni sociales; no se realizó validación externa ni temporal; los índices de clustering se calcularon sobre muestras; las asociaciones univariadas que orientaron la selección de variables se calcularon con toda la cohorte; algunas variables (p. ej. diagnósticos) podrían no estar codificadas al momento de decidir el seguimiento; y el análisis económico depende de supuestos de costo y efectividad no observados en los datos, incluida una efectividad constante entre niveles de riesgo.

6. Conclusiones

El KNN permite priorizar pacientes con un rendimiento acorde con la literatura (AUC 0.639; IC 95 %: 0.624–0.656), siempre que sus probabilidades se recalibren y el umbral se derive de los costos de la intervención. Ni DBSCAN ni la GMM revelan subgrupos naturales: la población se comporta como un continuo, y las segmentaciones obtenidas son útiles para describir hospitalizaciones, pero no añaden capacidad predictiva. Metodológicamente, este trabajo muestra la importancia de evaluar sin fuga de información, reportar incertidumbre y calibración, y validar los clusters con índices apropiados, pruebas de robustez y criterios externos.

Referencias

- [1] Strack B, DeShazo JP, Gennings C, et al. Impact of HbA1c measurement on hospital readmission rates: analysis of 70,000 clinical database patient records. *BioMed Research International*. 2014;2014:781670.
- [2] Liu VB, Sue LY, Wu Y. Comparison of machine learning models for predicting 30-day readmission rates for patients with diabetes. *Journal of Medical Artificial Intelligence*. 2024.
- [3] Moulavi D, Jaskowiak PA, Campello RJGB, Zimek A, Sander J. Density-based clustering validation. *Proc. SIAM International Conference on Data Mining*. 2014:839–847.
- [4] Hennig C. Cluster-wise assessment of cluster stability. *Computational Statistics & Data Analysis*. 2007;52(1):258–271.
- [5] Biernacki C, Celeux G, Govaert G. Assessing a mixture model for clustering with the integrated completed likelihood. *IEEE TPAMI*. 2000;22(7):719–725.
- [6] Schubert E, Sander J, Ester M, Kriegel HP, Xu X. DBSCAN revisited, revisited: why and how you should (still) use DBSCAN. *ACM Transactions on Database Systems*. 2017;42(3):19.
- [7] Vickers AJ, Elkin EB. Decision curve analysis: a novel method for evaluating prediction models. *Medical Decision Making*. 2006;26(6):565–574.
- [8] van den Goorbergh R, van Smeden M, Timmerman D, Van Calster B. The harm of class imbalance corrections for risk prediction models. *JAMIA*. 2022;29(9):1525–1534.
- [9] Van Calster B, McLernon DJ, van Smeden M, et al. Calibration: the Achilles heel of predictive analytics. *BMC Medicine*. 2019;17:230.